

Materi Pertemuan 13


High Availability (HA)

Arsitektur Sistem dengan Ketersediaan Tinggi

"Tujuan akhir kita bukan hanya membuat sistem yang jalan, tapi sistem yang tetap jalan meskipun ada komponen yang terbakar atau mati."

Target Pembelajaran

Mahasiswa mampu merancang, mengonfigurasi, dan mengelola solusi infrastruktur High Availability pada lingkungan cloud untuk menjamin keberlangsungan layanan.



Uptime Target
Five Nines (99.999%)

Agenda Pembelajaran



1



Konsep Dasar HA

Definisi, Uptime "The Nines" (99.999%), & SPOF.

2



Strategi Redundansi

Active-Active vs Active-Passive & Mekanisme Failover.

3



Komponen Infrastruktur

Load Balancer, Floating IP, & Replikasi Database.

4



Arsitektur Multi-Zone

Strategi deployment lintas Availability Zone (AZ) & Region.

5



Disaster Recovery (DR)

Perbedaan HA vs DR, serta metrik RTO & RPO.

6



Pengujian Keandalan

Chaos Engineering & validasi skenario kegagalan.

7



Desain arsitektur fault-tolerant untuk sistem perbankan.



"High Availability bukan sekadar mencegah downtime, tapi menjamin keberlangsungan bisnis di tengah kegagalan sistem yang tak terelakkan."

Definisi High Availability (HA)

Apa itu HA?

Kemampuan sistem atau komponen untuk beroperasi secara terus-menerus dalam jangka waktu yang lama dengan tingkat downtime yang sangat minimal.

Tiga Karakteristik Utama



Redundansi (Redundancy)

Duplikasi komponen kritis (server, DB, network) untuk menghilangkan titik kegagalan tunggal.




Failover Otomatis

Mekanisme perpindahan otomatis ke sistem cadangan tanpa intervensi manusia saat terjadi kegagalan.



Monitoring Real-time

Pemantauan kesehatan sistem secara terus menerus untuk mendeteksi anomali seketika.



Konsep "The Nines"

Standar Pengukuran Persentase Uptime & Toleransi Downtime



Availability	Nines	Downtime / Tahun	Level Layanan
99%	"Two Nines"	3.65 Hari	Website Personal / Internal Dev
99.9%	"Three Nines"	8.76 Jam	Aplikasi Bisnis Standar
99.99%	"Four Nines"	52.6 Menit	Enterprise Critical
99.999% 🏆	"Five Nines"	5.26 Menit	Banking / Telecom / Medical

💡 Insight

Setiap penambahan satu angka "9" di belakang koma, biaya infrastruktur biasanya meningkat secara **eksponensial**, bukan linear.

Rumus Availability:

$$(\text{Uptime} / \text{Total Time}) \times 100\%$$



100% Uptime sangat sulit dicapai karena adanya *Scheduled Maintenance*.

Single Point of Failure (SPOF)

Identifikasi Titik Lemah dalam Arsitektur Sistem



! Definisi SPOF

Satu komponen atau bagian dari sistem yang, jika mengalami kegagalan, akan menyebabkan **penghentian operasional seluruh sistem** (Total Outage).

Analogi Rangkaian Seri



Contoh Umum di Infrastruktur



Single App Server

Jika server fisik rusak atau OS crash, aplikasi tidak bisa diakses sama sekali.



Single Database Instance

Database tunggal adalah SPOF paling kritis. Jika korup, data hilang dan layanan berhenti.



Single Network Switch/Gateway

Satu jalur jaringan putus memutuskan koneksi internet ke semua server di belakangnya.

✓ Strategi Eliminasi

Satu-satunya cara menghilangkan SPOF adalah dengan menerapkan **Redundansi (N+1)** pada setiap lapisan arsitektur.

Load Balancer



Multiple Server



Replicated DB

Redundansi: Active-Passive vs Active-Active

Memilih strategi failover yang tepat berdasarkan kebutuhan bisnis



FAILOVER

Active-Passive

Cold/Warm Standby



Cara Kerja

Satu node (**Primary**) menangani seluruh trafik. Node kedua (**Standby**) diam dan hanya aktif jika Primary mati.

Use Case

- ✓ Database SQL (Master-Slave)
- ✓ Aplikasi dengan lisensi per-core
- ✓ Sistem Legacy non-cluster

LOAD BALANCED

Active-Active

Distributed Workload



Cara Kerja

Semua node **Aktif** melayani trafik secara bersamaan. Load Balancer membagi beban. Jika satu mati, trafik dialihkan ke yang lain.

Use Case

- ✓ Web Server / API (Stateless)
- ✓ High Traffic Applications
- ✓ Zero-Downtime Requirement

Mekanisme Failover Otomatis



Apa itu Automatic Failover?

Proses perpindahan beban kerja secara otomatis dari komponen utama (Primary) yang mengalami kegagalan ke komponen cadangan (Backup/Standby) tanpa memerlukan intervensi manusia, untuk meminimalkan downtime layanan.

Alur Sequence Failover



TARGET RTO
< 60 Detik

**Waktu pemulihan bergantung pada TTL DNS dan kecepatan startup aplikasi di server standby.*



Zero-Touch Recovery


Memastikan Business Continuity

Load Balancer dalam HA

Distribusi Trafik & Mekanisme Self-Healing Otomatis



Arsitektur Traffic Routing



Fungsi Vital HA

1. Continuous Health Checks

LB mengirim sinyal ("ping") setiap beberapa detik. Jika server tidak merespons (timeout/error 500), server ditandai sebagai **Unhealthy**.

2. Automatic Removal (Circuit Breaker)

Server mati langsung dikeluarkan dari pool. Trafik pengguna **tidak pernah** diarahkan ke server rusak, mencegah error page.

3. Seamless Recovery

Saat server sembuh dan lolos health check, LB otomatis memasukkannya kembali ke pool trafik.

Algoritma Distribusi

Round Robin

Membagi urut secara bergantian (A -> B -> C -> A).

Least Connection

Mengirim ke server dengan koneksi aktif paling sedikit.

Multi-Zone Architecture

Proteksi Terhadap Kegagalan Pusat Data (Datacenter Failure)



Konsep Availability Zone (AZ)

AZ adalah satu atau lebih pusat data diskrit dengan daya, jaringan, dan konektivitas redundan dalam satu **Region** AWS/GCP/Azure.



Isolasi Kegagalan

Jika satu gedung mati lampu/kebanjiran, AZ lain tetap hidup.




Replikasi Synchronous

Data ditulis ke database di multiple AZ secara real-time.



Low Latency

Jarak antar AZ < 100km, latensi < 2ms (terasa seperti LAN lokal).




Database Replication

Synchronous vs Asynchronous Replication Models



Synchronous

Strong Consistency (RPO = 0)



Zero Data Loss

Data ditulis ke semua node sebelum transaksi selesai.



Write Penalty


Performa tulis mengikuti replika paling lambat.

Best Use Case

Banking, Payment Systems, Inventory (Critical Data)

Asynchronous

Eventual Consistency (RPO > 0)



High Performance

Aplikasi tidak menunggu replika. User experience cepat.



Risk of Data Loss

Jika primary mati sebelum sync, data terakhir hilang.

Best Use Case

Social Media Feeds, Analytics, Logging, Non-Critical Apps

Floating IP & Anycast IP

Strategi Pengalamatan Jaringan untuk High Availability




Floating IP

Local Failover Strategy



Alamat IP statis yang dapat **dipindahkan** (remapped) secara instan dari satu server ke server lain dalam satu region/datacenter yang sama saat terjadi kegagalan.



Contoh Penggunaan

Failover Database (Active-Passive)

Upgrading server tanpa ganti DNS


Pindah traffic antar Load Balancer

Anycast IP

Global Distribution Strategy



Satu alamat IP yang sama diumumkan dari berbagai lokasi geografis. Jaringan secara otomatis merutekan user ke server **terdekat** secara topologi.



Contoh Penggunaan

Global DNS (Google 8.8.8.8, Cloudflare 1.1.1.1)

Content Delivery Network (CDN)

DDoS Protection (menyebarkan serangan)

Disaster Recovery vs High Availability

Memahami perbedaan cakupan dan target pemulihan



High Availability (HA)

Business as Usual



Tujuan Mencegah Downtime (Prevent)

Strategi Redundansi & Failover Otomatis

Skala Kegagalan komponen tunggal / lokal

RTO Detik - Menit

RPO Near Zero (Real-time Sync)

i Contoh: Web server crash, Load Balancer mengalihkan trafik ke node sehat. User tidak sadar.

VS

Disaster Recovery (DR)

Emergency Response



Tujuan Memulihkan Layanan (Recover)

Strategi Backup/Restore & Site Replication

Skala Bencana alam, Datacenter mati total

RTO Jam - Hari

RPO Menit - Jam

i Contoh: Data center Jakarta banjir total. Mengaktifkan site backup di Surabaya via DNS switch.



Pendekatan Komplementer

HA dan DR bukanlah pilihan "salah satu", melainkan lapisan pertahanan yang saling melengkapi. **HA** menangani kegagalan operasional harian (99% kasus), sedangkan **DR** adalah asuransi terakhir untuk kejadian katastrofik (1% kasus).


- ✓ HA: User Experience
- ✓ DR: Data Survival

RTO & RPO Metrics

Parameter Kunci dalam Perencanaan Keberlangsungan Layanan



Visualisasi Timeline Insiden



Recovery Point Objective

Max Data Loss Tolerance

Titik waktu maksimal di masa lalu di mana data dapat dipulihkan. Menentukan seberapa sering backup harus dilakukan.

TARGET CONTOH: 5 Menit



Dampak Bisnis

Transaksi yang terjadi antara 10:00 - 10:05 akan hilang permanen dan perlu diinput ulang manual.



Recovery Time Objective

Max Downtime Tolerance

Durasi waktu maksimal yang diperbolehkan untuk sistem mati sebelum pulih kembali normal setelah insiden.

TARGET CONTOH: 15 Menit



Dampak Bisnis

Layanan terhenti total selama 15 menit. Potensi kerugian revenue dan reputasi selama durasi ini.

Multi-Region Architecture

Strategi Replikasi Global untuk Disaster Recovery & Latency Reduction



Global Traffic Management

Anycast IP atau Global DNS mengarahkan pengguna ke region terdekat (Geo-Routing). Jika satu region mati, trafik otomatis dialihkan ke region lain.



Cross-Region Replication

Replikasi database secara **Asynchronous** antar benua untuk Disaster Recovery (DR). Data aman meskipun terjadi bencana alam skala besar.



Latency Reduction

Konten statis di-cache via CDN, aplikasi berjalan dekat dengan user. Latensi berkurang drastis (contoh: 200ms → 20ms).



Ultimate Resilience

"Multi-Region adalah pertahanan terakhir. Ketika satu negara offline, bisnis tetap berjalan di negara lain."

● Active Region

● User Traffic

— Replication

Chaos Engineering

Membangun Sistem Tangguh dengan Kegagalan Terkontrol



Definisi


Disiplin melakukan eksperimen pada sistem terdistribusi untuk membangun kepercayaan terhadap kemampuan sistem bertahan dari kondisi turbulen di lingkungan produksi.

Prinsip Netflix

Chaos Monkey

"Secara acak mematikan server di jam kerja agar tim terbiasa menangani kegagalan, bukan takut padanya."

Visualisasi Konsep: Controlled Failure



Contoh Eksperimen



Resource Failure

Shutdown random EC2 instance atau Pod.



Network Latency

Inject delay 500ms pada koneksi database.

Zone Outage

Simulasi satu Availability Zone mati total.

Tools Populer



Chaos Monkey (Netflix)



Gremlin (SaaS)



LitmusChaos (K8s Native)



Chaos Mesh

Testing High Availability Systems

Metodologi Validasi Ketangguhan Infrastruktur (Chaos & Resilience)



HA Verification Checklist



1. Failover Testing



Matikan server **Primary** secara paksa (kill process/shutdown). Verifikasi **Secondary** mengambil alih dalam < 60 detik.



2. Load Testing



Simulasikan lonjakan trafik **3x-5x** lipat. Pastikan autoscaling aktif dan latency tetap stabil.



3. Zone Failure Sim



Putus koneksi ke satu **Availability Zone**. Verifikasi sistem tetap berjalan di AZ lain tanpa error 500.



4. Network Partition



Uji skenario "Split Brain". Pastikan database tidak korup dan konsistensi data terjaga saat network putus.



5. Replication Monitor



Ukur lag replikasi DB saat beban tinggi. Pastikan sesuai dengan target **RPO** (misal < 5 detik).



6. Backup & Restore



Lakukan restore data dari backup acak ke environment staging. Verifikasi integritas data hasil restore.



Jadwal Testing

Q3

Quarterly

Disaster Recovery Drill

Dilakukan setiap 3 bulan di environment Staging/Production (saat maintenance window).



Verification Metrics

Actual RTO vs Target: Apakah sistem pulih dalam batas waktu yang ditentukan?

Error Rate %: Berapa % request gagal selama proses failover berlangsung?
(Target: < 0.1%)

Data Integrity Check: Apakah checksum data di Primary dan Secondary identik setelah recovery?

Alert Latency: Berapa lama waktu dari kejadian failure hingga tim on-call menerima notifikasi?

Referensi Akademis



Teori & Konsep

Fundamental Arsitektur

Cloud Computing: Concepts, Technology & Architecture

Erl, Thomas. (2013). Prentice Hall.

Bab: Cloud Management Mechanisms (HA)

Site Reliability Engineering

Beyer, B., Jones, C., et al. (2016). Google/O'Reilly.

Bab: Embracing Risk & Service Level Objectives (SLOs)



Infrastruktur Cloud

Dokumentasi Teknis

AWS Architecture Center

Amazon Web Services

Topik: High Availability Whitepapers

Azure Reliability Documentation

Microsoft Learn

Topik: Availability Zones and Regions



Desain Sistem

Pola Robustness

Designing Robust Systems

Google Cloud Architecture Center

Pola Desain: Redundansi & Failover

The NIST Definition of Cloud Computing

Mell, P., & Grance, T. (2011). NIST.

Standar: Resource Pooling & Rapid Elasticity

Skenario: Layanan Perbankan Online

Merancang Arsitektur High Availability untuk Sistem Kritis



Bank JTI Digital

Core Banking System

Target Uptime

99.99%

"Four Nines"

Max Downtime

52m

per Tahun

Karakteristik Layanan:

- ✓ Transaksi finansial real-time 24/7.
- ✓ Data konsistensi mutlak (Zero Data Loss).
- ✓ Pengguna tersebar di seluruh Indonesia.

Simulasi Ancaman

Kebakaran hebat terjadi di **Data Center Jakarta (Zone A)**. Seluruh server di zona tersebut mati total (Total Power Outage).

Tugas Perancangan Arsitektur

1 Desain Topologi Multi-AZ

Architecture

Rancang arsitektur yang tersebar minimal di **2 Availability Zone** berbeda.



Load Balancer



Redundant Web Servers



Replicated Database

2 Identifikasi & Eliminasi SPOF

Analysis

Tunjukkan komponen mana yang berpotensi menjadi *Single Point of Failure* dan bagaimana desain Anda menghilangkannya.

3 Pilih Strategi Redundansi

Decision

Tentukan strategi untuk Web Server dan Database. Jelaskan alasannya.

Web Tier: Active-Active / Active-Passive?

DB Tier: Sync / Async Replication?

4 Estimasi RTO & RPO

Metrics

Berapa lama sistem kembali online (RTO) jika Zone A mati? Berapa banyak data yang mungkin hilang (RPO)? Apakah memenuhi target 99.99%?

Tugas Studi Kasus HA

Desain Arsitektur Fault-Tolerant Aplikasi Perbankan



Instruksi Pengerjaan

1

Desain Topologi Multi-AZ

Rancang arsitektur sistem yang mencakup **Load Balancer**, **Web Server Cluster** (Redundan), dan **Database Replication**. Pastikan sistem tersebar di minimal 2 Availability Zone (AZ).

2

Analisis & Strategi Resilience

Tentukan strategi failover (Active-Active atau Active-Passive) dan estimasi target **RTO/RPO**. Jelaskan skenario jika satu pusat data mati total.

3

Laporan & Deliverables

Susun laporan PDF yang berisi diagram arsitektur (draw.io/visio), dokumentasi skenario kegagalan, dan evaluasi eliminasi SPOF.



Rubrik Penilaian

Total Bobot: 100 Poin

40 Poin

Eliminasi SPOF

Analisis tajam dalam mengidentifikasi dan menghilangkan Single Point of Failure (SPOF) pada setiap layer infrastruktur.

30 Poin

Pilihan Redundansi

Ketepatan pemilihan topologi redundansi (Active-Active/Passive) dan strategi replikasi database sesuai kebutuhan perbankan.

30 Poin

Dokumen Failover

Kejelasan skenario failover dan logika pemulihan sistem (Self-healing) sesuai standar RPS.

Format: PDF (Laporan) + Diagram



RECAP

Summary Pertemuan 13

High Availability (HA) adalah standar arsitektur modern untuk menjamin keberlangsungan layanan bisnis dan meminimalisir dampak kegagalan infrastruktur.

Capaian Pembelajaran

- ✓ Konsep The Nines
- ✓ Eliminasi SPOF
- ✓ Arsitektur Fault-Tolerant



Uptime & The Nines

HA memastikan sistem beroperasi terus-menerus. Target ketersediaan diukur dengan "The Nines" (misal 99.99%), di mana toleransi downtime sangat ketat.



Redundansi & Failover

Kunci HA adalah mengeliminasi **SPOF** melalui redundansi komponen dan mekanisme **failover otomatis** untuk mengurangi durasi gangguan layanan.



Proteksi Multi-Zone

Load Balancing mendistribusi beban, sementara penyebaran **Multi-Zone/Region** melindungi sistem dari bencana lokal atau kegagalan total pusat data.



Resilience & Trade-off

Ketahanan wajib divalidasi dengan **Testing Regular** (Chaos Engineering). Selalu pertimbangkan trade-off antara biaya infrastruktur dan tingkat availability.